1. 空间局部性利用

• **原理**:较大的块能一次性加载更多相邻数据,利用程序的**空间局部性**(相邻数据可能被连续访问)。

• 效果: 若后续访问集中在同一块内,则减少缺失次数(如遍历数组时)。

• 风险: 块过大时, 可能加载无用数据, 浪费带宽和缓存容量(污染缓存)。

2. 时间局部性与冲突

• 原理: 较小的块能容纳更多独立数据项,利用时间局部性(同一数据被重复访问)。

• 效果:减少缓存行间的冲突(Conflict Miss),尤其在小容量缓存中。

• 风险: 块过小可能无法充分利用空间局部性, 增加缺失率。

3. 权衡点 (Trade-off)

• **最佳块大小**:需平衡空间与时间局部性,通常由硬件设计通过实验确定(如CPU缓存常用64字节块)。

o **过小**: 缺失率因空间局部性未充分利用而升高。

o **过大**:缓存行数减少,导致容量/冲突缺失增加,且传输延迟上升。

4. 其他因素

• 缺失惩罚 (Miss Penalty): 块越大, 传输时间越长, 但可能因减少缺失次数而整体优化。

• 多级缓存: L1缓存常用较小块(低延迟), L2/L3可能用较大块(高命中率)。

示例

• 高空间局部性场景(如顺序访问): 增大块可降低缺失率。

• 随机访问场景: 小块更优, 避免加载无用数据。

通过调整块大小,缓存系统能在局部性利用与资源效率间取得平衡,从而优化整体性能。